Statistiques et Optimisation pour Machine Learning

Zouhir ERRAJI

Objectifs du module

- Comprendre les bases probabilistes du Machine Learning
- Maîtriser les modèles statistiques fondamentaux
- Comprendre l'optimisation des fonctions de coût

Expérience aléatoire

Définition

Une expérience aléatoire est une expérience dont :

- On connaît les résultats possibles
- On ne peut pas prévoir le résultat exact à l'avance

Exemples :

- Lancer une pièce
- Lancer un dé
- Mesurer la température demain
- Prédire si un email est Spam

Espace des résultats

On note Ω l'ensemble des résultats possibles.

Exemples :

- Pièce : $\Omega = \{Pile, Face\}$
- Dé : $\Omega = \{1, 2, 3, 4, 5, 6\}$
- Email : $\Omega = \{Spam, NonSpam\}$

Espace probabilisé

Un espace probabilisé est un triplet :

$$(\Omega, \mathcal{F}, P)$$

où :

- Ω : ensemble des issues= L'univers des possibilté
- $\mathcal{F}$: ensemble des événements
- P : mesure de probabilité

Les événements

Un événement est un sous-ensemble de Ω.
Exemple : dé

$$A = \{2, 4, 6\}$$

événement : "obtenir un nombre pair"

Propriétés de la probabilité

La probabilté est une fonction $P : \mathcal{F} \to [0, 1]$ vérifie :

1. $P(A) \geq 0$
2. $P(\Omega) = 1$
3. Si $A \cap B = \emptyset$ alors
$$P(A \cup B) = P(A) + P(B)$$

Probabilité conditionnelle

Définition
Si $P(B) > 0$:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

$P(A|B)$ = probabilité de A sachant que B est (sera) réalisé. On restreint l'univers à B.
Donc l'intersection s'exprime :

$$P(A \cap B) = P(A|B)P(B)$$

Exemple

Dé équilibré.
A : nombre pair B : nombre > 3

$$A = \{2, 4, 6\} \quad B = \{4, 5, 6\}$$

$$P(A|B) = \frac{2}{3}$$

Indépendance

Deux événements A et B sont indépendants si :

$$P(A \cap B) = P(A)P(B)$$

Équivalent à :

$$P(A|B) = P(A)$$

Indépendance = l'information sur B ne change rien sur A.

Exemple d'indépendance

Deux lancers de pièce.
A : premier lancer = Pile B : deuxième lancer = Pile

$$P(A \cap B) = \frac{1}{4}$$

$$P(A)P(B) = \frac{1}{2} \times \frac{1}{2} = \frac{1}{4}$$

Donc indépendants.

Probabilité composée : définition

La **probabilité composée** exprime la probabilité de l'intersection de deux événements A et B :

$$P(A \cap B) = P(A) \cdot P(B|A) = P(B) \cdot P(A|B)$$

où $P(B|A)$ est la **probabilité conditionnelle** de B sachant A.
Exemple Un sac contient 3 boules rouges et 2 boules bleues. On tire deux boules successivement sans remise.

$$P(\text{Rouge puis Bleue}) = P(R_1) \cdot P(B_2|R_1) = \frac{3}{5} \cdot \frac{2}{4} = \frac{3}{10}$$

Plus généralement :

$$P(A_1 \cap \cdots \cap A_n) = P(A_1) \prod_{i=2}^{n} P(A_i|A_1, \ldots, A_{i-1})$$

Théorème des probabilités totales

Soit $\{C_1, C_2, \ldots, C_n\}$ une **partition de l'univers** Ω, c'est-à-dire :

$$C_i \cap C_j = \emptyset \text{ pour } i \neq j \quad \text{et} \quad \bigcup_{i=1}^{n} C_i = \Omega$$

Alors, pour tout événement A :

$$\boxed{P(A) = \sum_{i=1}^{n} P(A \cap C_i) = \sum_{i=1}^{n} P(A|C_i)P(C_i)}$$

Exemple : Un produit peut provenir de 3 usines : C_1, C_2, C_3, avec $P(C_1) = 0.4$, $P(C_2) = 0.35$, $P(C_3) = 0.25$. Probabilité de défaut A : $P(A|C_1) = 0.01$, $P(A|C_2) = 0.02$, $P(A|C_3) = 0.03$

$$P(A) = 0.4 \cdot 0.01 + 0.35 \cdot 0.02 + 0.25 \cdot 0.03 = 0.019$$

Théorème de Bayes

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

Où :

- $P(A)$: probabilité a priori
- $P(A|B)$: probabilité a posteriori
- $P(B)$: constante de normalisation

Exemple : Test médical

Une maladie touche 1% de la population :

$$P(M) = 0.01$$

Le test :

- Sensibilité : $P(+ \mid M) = 0.9$
- Faux positif : $P(+ \mid \bar{M}) = 0.05$

Question :

$$P(M \mid +) \ ?$$

Étape 1 : Calcul de $P(+)$

$$P(+) = P(+ \mid M)P(M) + P(+ \mid \bar{M})P(\bar{M})$$

$$= 0.9 \times 0.01 + 0.05 \times 0.99$$

$$= 0.009 + 0.0495 = 0.0585$$

Étape 2 : Application de Bayes

$$P(M \mid +) = \frac{P(+ \mid M)P(M)}{P(+)}$$

$$= \frac{0.9 \times 0.01}{0.0585} = \frac{0.009}{0.0585} \approx 0.154$$

$$\boxed{P(M \mid +) \approx 15.4\%}$$

Cas discret général

Pour une partition $(C_1, \ldots, C_K)$:

$$P(C_k|X) = \frac{P(X|C_k)P(C_k)}{\sum_{j=1}^{K} P(X|C_j)P(C_j)}$$

Formule centrale du Machine Learning probabiliste.

Formule de décision

$$P(C_k|X) = \frac{P(X|C_k)P(C_k)}{P(X)}$$

Comme $P(X)$ est constant :

$$\hat{y} = \arg\max_k P(X|C_k)P(C_k)$$

Hypothèse d'indépendance conditionnelle

Pour $X = (X_1, \ldots, X_d)$
Naive Bayes suppose :

$$P(X|C_k) = \prod_{i=1}^{d} P(X_i|C_k)$$

Hypothèse forte mais efficace en pratique.

Règle de décision finale

$$\hat{y} = \arg\max_k P(C_k) \prod_{i=1}^{d} P(X_i|C_k) := \arg\max_k Scor(C_k)$$

Exemple : Classification Spam

Classes :

$$C_1 = \text{Spam}, \quad C_2 = \text{Non Spam}$$

Caractéristiques :

$$X_1 = \text{"gratuit"}$$

$$X_2 = \text{"promotion"}$$

Nous voulons répondre à la question : **Ce message est-il un Spam ou non ?**

Calcul des probabilités

La base d'apprentissage (la base d'entraînement) : Dans une boite : P(Spam)=0.4 et P(NonSpam)=0.6. On compte le nombre de repetition des mot "gratuit" et "promotion" dans toute la boite, si on trouve par ex :

$$P(\text{gratuit}|Spam) = 0.8$$

$$P(\text{promotion}|Spam) = 0.7$$

Alors :

$$Score(Spam) = 0.4 \times 0.8 \times 0.7 = 0.224$$

Calcul pour la classe Non-Spam

et

$$P(\text{gratuit}|NonSpam) = 0.1$$

$$P(\text{promotion}|NonSpam) = 0.2$$

Alors :

$$Score(NonSpam) = 0.6 \times 0.1 \times 0.2 = 0.012$$

Comparaison des scores

$$Score(Spam) > Score(NonSpam)$$

Alors :

$$\hat{y} = Spam$$

Ainsi, Le classifieur Naive Bayes prédit que : Le message est Spam.
Exr ...

Résumé :

- Problème : classification supervisée
- Objectif : prédire la classe Y à partir des variables $X = (X_1, \ldots, X_d)$

$$\hat{y} = \arg\max_{y \in \mathcal{Y}} P(Y = y \mid X = x)$$

$$= \arg\max_{y} P(Y = y) \prod_{j=1}^{d} P(X_j \mid Y = y)$$

Algorithme (cas discret)

Phase d'apprentissage :

- Estimer $P(Y = y)$
- Estimer $P(X_j = x_j \mid Y = y)$

Phase de prédiction :

- Calculer le score pour chaque classe
- Choisir la classe maximisant le score

Types de Naive Bayes

- **Bernoulli NB** : variables binaires
- **Multinomial NB** : texte (fréquence de mots)
- **Gaussian NB** : variables continues

Cas Gaussien :

$$P(X_j \mid Y = y) = \frac{1}{\sqrt{2\pi\sigma_y^2}} \exp\left(-\frac{(x_j - m_y)^2}{2\sigma_y^2}\right)$$

2) Variables aléatoires

- Variables discrètes et continues
- Fonction de répartition
- Espérance et variance
- Lois classiques (Bernoulli, Binomiale, Normale)

Définition : Variable aléatoire

Idée intuitive
Une variable aléatoire transforme un résultat abstrait en nombre.
Définition
Une variable aléatoire X est une application :

$$X : \Omega \to \mathbb{R}$$

Elle associe à chaque issue $\omega \in \Omega$ un nombre réel.

Exemple simple

Lancer un dé :

$$\Omega = \{1, 2, 3, 4, 5, 6\}$$

On définit :

$$X(\omega) = \omega^2$$

Ici X est la valeur obtenue.

Autre exemple

Classification email :

$$\Omega = \{succs, chec\}$$

On code :

$$X(succs) = 1, \quad X(chec) = 0$$

Le ML travaille toujours avec des variables numériques.

Variable aléatoire discrète

X est discrète si elle prend un nombre fini ou dénombrable de valeurs qu'on note $X(\Omega) = \{x_1, ..., x_i, ...\}$.
On définit la loi de probabilité :

$$P(X = x_i) == \text{La probabilté que} \quad X \quad \text{egale à} \quad x_i$$

avec :

$$\sum_i P(X = x_i) = 1$$

Dans l'exemple precédent $X(\Omega) = \{0, 1\}$, et la loi de probabilté est P(X = 1)= p (probabilté de succès) et P(X = 0)= ...

Variable Continue : Densité de probabilité

Une fonction f :$\mathbb{R} \to \mathbb{R}$. est dite **densité de probabilité** si les conditions suivantes sont vérifiées :

$$f(x) \geq 0 \qquad \forall x \in \mathbb{R}$$

$$\int_{-\infty}^{+\infty} f(x), dx = 1$$

Pour tout intervalle ([a,b]$\subset \mathbb{R}$),

$$P(a \leq X \leq b) = \int_a^b f(x), dx$$

Variable aléatoire continue

La va X est dite continue si elle admet une densité f telle que :
Pour tout intervalle ([a,b]$\subset \mathbb{R}$), :

$$P(a \leq X \leq b) = \int_a^b f(x)\, dx$$

Espérance

Espérance (discret)

$$\mathbb{E}[X] = \sum_i x_i P(X = x_i)$$

Espérance (continu)

$$\mathbb{E}[X] = \int_{-\infty}^{+\infty} x f(x)\, dx$$

Interprétation : moyenne théorique.

Variance

La variance mesure la dispersion autour de la moyenne.

$$\mathrm{Var}(X) = \mathbb{E}\left[(X - \mathbb{E}[X])^2\right]$$

Formule pratique :

$$\mathrm{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$$

Interprétation :

- Variance faible $\rightarrow$ données concentrées
- Variance grande $\rightarrow$ données dispersées

Fondamental pour comprendre le surapprentissage.

Linéarité de l'espérance

Soient X et Y deux variables aléatoires et $a, b \in \mathbb{R}$.

Propriété de linéarité

$$E(aX + bY) = aE(X) + bE(Y)$$

- Cette propriété est valable **même si X et Y ne sont pas indépendantes**.
- Elle se généralise à plusieurs variables aléatoires :

$$E\left(\sum_{i=1}^{n} a_i X_i\right) = \sum_{i=1}^{n} a_i E(X_i)$$

Propriétés de la variance

Soit X une variable aléatoire et $a, b \in \mathbb{R}$.

Variance d'une transformation linéaire

$$Var(aX + b) = a^2 Var(X)$$

Variance d'une somme

$$Var(X + Y) = Var(X) + Var(Y)$$

si X et Y sont indépendantes.

L'écart type

$$\sigma_X = \sqrt{\mathrm{Var}(X)}$$

Covariance

Pour deux variables X et Y :

$$\mathrm{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}(X))(Y - \mathbb{E}(Y)]$$

Mesure la **variation conjointe** entre X et Y.

- $Cov(X, Y) > 0$: les variables évoluent dans le même sens
- $Cov(X, Y) < 0$: les variables évoluent en sens opposé
- $Cov(X, Y) = 0$: absence de relation linéaire

Corrélation

$$\rho(X, Y) = \frac{\mathrm{Cov}(X, Y)}{\sigma_X \sigma_Y}$$

Elle mesure la **force de la relation linéaire** entre X et Y

- $\rho = 1$: corrélation parfaite
- $\rho = 0$: non corrélées

Rôle en Machine Learning

- Détection des **relations entre variables**
- **Sélection de variables** (feature selection)
- Réduction de dimension (ex : **PCA**)
- Analyse de la **redondance entre features**

Exemples concrets en Machine Learning

- **Détection des relations entre variables**
  Exemple : dans un modèle de prédiction du **prix des maisons**, la variable *surface* est souvent fortement corrélée avec le *prix*. Une corrélation positive indique que lorsque la surface augmente, le prix augmente.
- **Sélection de variables (Feature Selection)**
  Exemple : pour prédire le **risque de diabète**, on peut analyser la corrélation entre les variables (âge, IMC, taux de glucose). Les variables ayant une forte corrélation avec la cible sont conservées dans le modèle.

- **Réduction de dimension (PCA)**
  Exemple : dans la **reconnaissance d'images**, une image peut contenir des milliers de pixels. La méthode PCA utilise la matrice de covariance pour transformer ces variables en quelques composantes principales qui résument l'information importante.

Exemple concrèt

Considérons les données utilisé pour prédire le prix d'une maison en fonction de sa surface.

$$X = \text{surface } (\text{m}^2), \qquad Y = \text{prix}$$

Données observées :

X	Y
50	150
60	180
80	240
100	300

$$E(X) = \frac{50 + 60 + 80 + 100}{4} = 72.5$$

$$E(Y) = \frac{150 + 180 + 240 + 300}{4} = 217.5$$

$$Cov(X, Y) = \frac{1}{n}\sum_{i=1}^{n}(x_i - E(X))(y_i - E(Y))$$

Détail du calcul :

$$(50 - 72.5)(150 - 217.5) = (-22.5)(-67.5) = 1518.75$$
$$(60 - 72.5)(180 - 217.5) = (-12.5)(-37.5) = 468.75$$
$$(80 - 72.5)(240 - 217.5) = (7.5)(22.5) = 168.75$$
$$(100 - 72.5)(300 - 217.5) = (27.5)(82.5) = 2268.75$$

$$Cov(X, Y) = \frac{4425}{4} = 1106.25$$

Covariance positive $\Rightarrow$ relation croissante.

$$\sigma_X = \sqrt{\frac{1}{n}\sum(x_i - E(X))^2}$$

$$(50 - 72.5)^2 = (-22.5)^2 = 506.25$$
$$(60 - 72.5)^2 = (-12.5)^2 = 156.25$$
$$(80 - 72.5)^2 = (7.5)^2 = 56.25$$
$$(100 - 72.5)^2 = (27.5)^2 = 756.25$$

$$\sigma_X = \sqrt{\frac{1475}{4}} = \sqrt{368.75} \approx 19.20$$

Analogue :

$$\sigma_Y = \sqrt{\frac{13275}{4}} = \sqrt{3318.75} \approx 57.61$$

Calcul de la corrélation

$$\rho(X, Y) = \frac{Cov(X, Y)}{\sigma_X \sigma_Y} = \frac{1106.25}{19.20 \times 57.61}$$

$$19.20 \times 57.61 \approx 1106.11$$

$$\rho(X, Y) \approx \frac{1106.25}{1106.11} \approx 1.0001$$

Soit $\rho(X, Y) \approx 1$: les variables sont fortement corrélées.
Une forte corrélation signifie que la variable X est utile pour prédire Y. Elle sera donc sélectionnée comme **feature importante** dans un modèle de régression.

Lois Classiques : Loi de Bernoulli

Une variable aléatoire X suit une loi de Bernoulli de paramètre p si :

$$X \in \{0, 1\}$$

avec :

$$P(X = 1) = p \quad P(X = 0) = 1 - p$$

On note :

$$X \sim \mathcal{B}(p)$$

Son Espérance et Variance

$$\mathbb{E}[X] = p$$
$$\mathrm{Var}(X) = p(1 - p)$$

Interprétation Machine Learning

Classification binaire :

$$Y \in \{0, 1\}$$

On modélise :

$$Y \sim \mathcal{B}(p(x))$$

La régression logistique consiste à modéliser :

$$p(x) = P(Y = 1 | X = x_i)$$

Loi Binomiale

Soit X le nombre de succès dans une série d'expériences indépendantes de Bernoulli $\mathcal{B}(p)$
On a $X(\Omega) = \{0, 1, ..., n\}$
On dit que X la loi binomial de paramétre n : nombre de répétitions ou d'essais et p : probabilité de succès à chaque essai
On note

$$X \sim \mathcal{B}(n, p)$$

Sa loi de Probabilité est :

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$$

Moments de loi Binomial

Si

$$X \sim \mathcal{B}(n, p)$$

Alors

$$\mathbb{E}[X] = np$$

$$\mathrm{Var}(X) = np(1-p)$$

Définition de la loi normale

Une variable aléatoire réelle X suit une loi normale (ou gaussienne) de paramètres μ (espérance) et σ^2 (variance) si sa densité de probabilité est donnée par :

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}, \quad x \in \mathbb{R}.$$

On note $X \sim \mathcal{N}(\mu, \sigma^2)$.

- μ est un paramètre de position (centre de la courbe).
- σ est un paramètre d'échelle (dispersion).
- La courbe est symétrique par rapport à μ, en forme de cloche.

Propriétés fondamentales

- Espérance : $E(X) = \mu$
- Variance : $Var(X) = \sigma^2$
- Écart-type : σ
- La loi normale est entièrement déterminée par ses deux premiers moments.
- Théorème central limite : la somme d'un grand nombre de variables aléatoires indépendantes tend vers une loi normale.

Loi normale centrée réduite

Si $X \sim \mathcal{N}(\mu, \sigma^2)$, alors la variable transformée

$$Z = \frac{X - \mu}{\sigma}$$

suit une loi normale d'espérance 0 et de variance 1, appelée **loi normale centrée réduite** et notée $\mathcal{N}(0, 1)$.
Sa densité est :

$$\varphi(z) = \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}}, \quad z \in \mathbb{R}.$$

Cette transformation est essentielle pour ramener tous les calculs de probabilités à une seule table.

Graphe de la densité de $\mathcal{N}(0,1)$

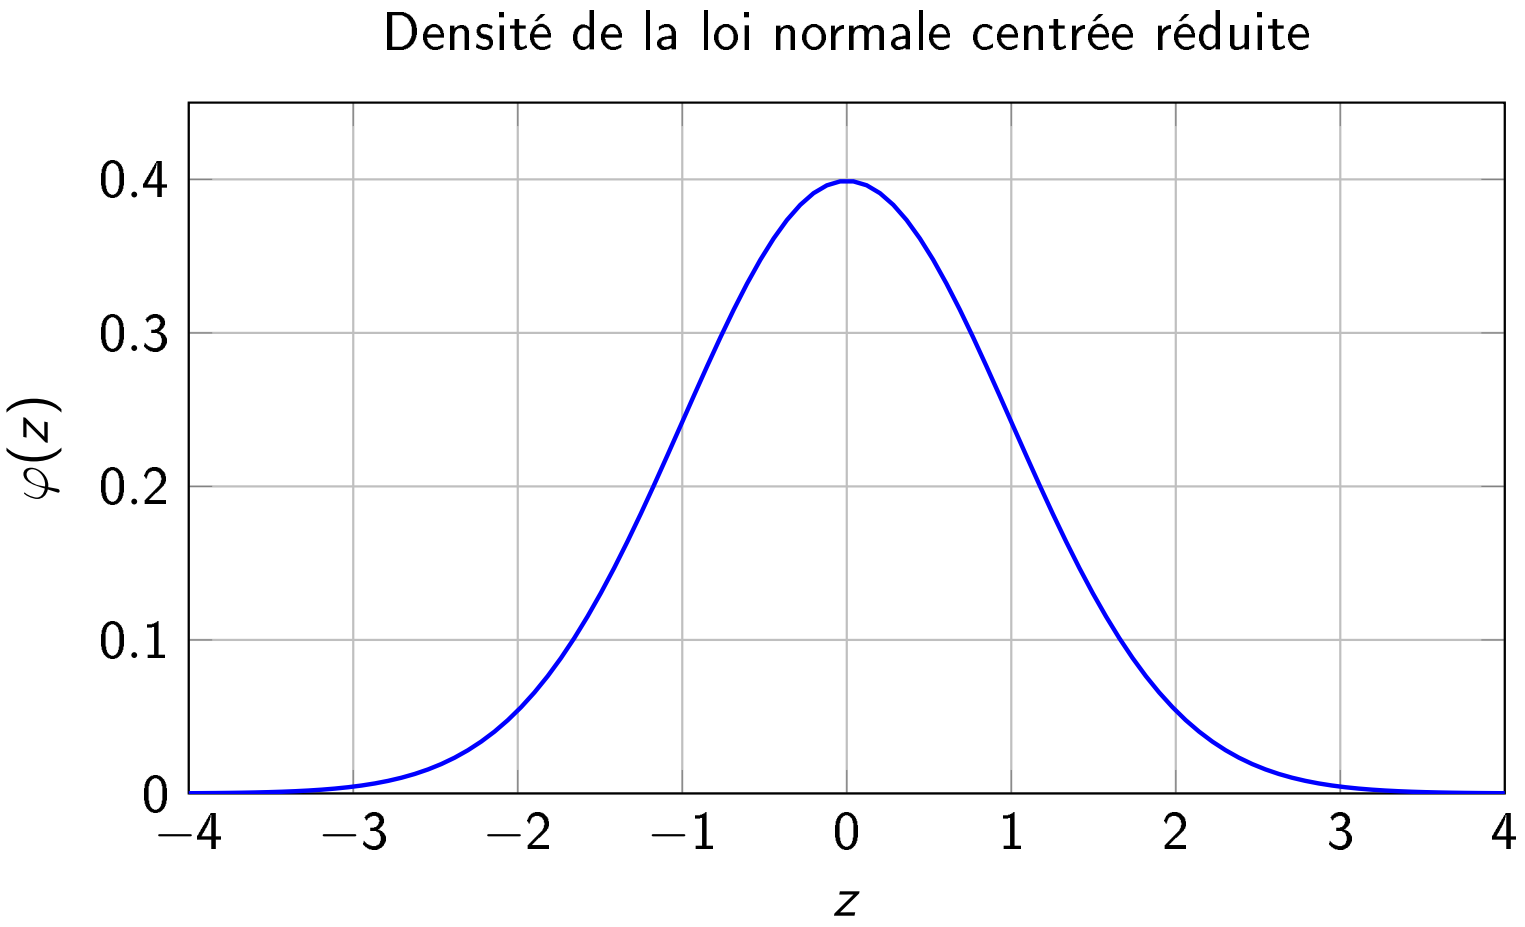

Propriétés de la fonction de répartition Φ de $\mathcal{N}(0,1)$

Pour $Z \sim \mathcal{N}(0,1)$, $\Phi(x) = P(Z \leq x) = \int_{-\infty}^{x} \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt$.

- **Symétrie :** $\Phi(-x) = 1 - \Phi(x)$.
- $\Phi(0) = 0.5$.
- $P(Z \geq a) = 1 - \Phi(a)$.
- Quantile d'ordre α : $\Phi(z_\alpha) = \alpha$.

4) Échantillonnage

- Population vs échantillon
- Estimateur de la moyenne
- Estimateur de la variance
- Notion de biais

Lien avec le Machine Learning :

Idée clé

En ML, on n'a jamais toute la population. On travaille toujours sur un échantillon.

Population vs Échantillon

Population

Ensemble complet des individus ou observations.

Exemple :

- Tous les emails existants.
- Tous les clients d'une banque.
- Tous les étudiants d'une université.

Échantillon

Sous-ensemble extrait de la population.

Pourquoi utiliser un échantillon ?

- Impossible d'observer toute la population.
- Trop coûteux.
- Données inaccessibles.

En Machine Learning :

La base d'entraînement est un échantillon de la réalité.

Paramètre vs Estimateur

Paramètre

Quantité inconnue de la population. Exemple : moyenne réelle m.

Estimateur

Formule calculée à partir de l'échantillon. Exemple : moyenne empirique $\bar{X}$.

Définition du biais

Le biais d'un estimateur $\hat{\theta}$ est :

$$\text{Biais}(\hat{\theta}) = \mathbb{E}[\hat{\theta}] - \theta$$

- Si biais $= 0 \rightarrow$ estimateur non biaisé.
- Sinon $\rightarrow$ estimateur biaisé.

Estimateur de la moyenne

Soit un échantillon :

$$X_1, X_2, \ldots, X_n$$

i.i.d. tels que :

$$\mathbb{E}[X_i] = m, \quad \mathrm{Var}(X_i) = \sigma^2.$$

La moyenne empirique est :

$$\bar{X} = \frac{1}{n} \sum_{i=1}^{n} X_i$$

Elle estime la moyenne réelle m.

$$\bar{X} \approx m$$

quand n est grand.

Preuve

Soit un échantillon :
La moyenne empirique est :

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$$

Alors :

$$\mathbb{E}[\bar{X}] == \frac{1}{n}\sum_{i=1}^{n} \mathbb{E}(X_i) = m$$

Alors l'estimateur estnon biaisé.

Estimateur de la Variance

Variance réelle :

$$\sigma^2 = \mathbb{E}[(X - m)^2]$$

Inconnue en pratique.
Estimateur empirique :

$$S^2 = \frac{1}{n-1} \sum_{i=1}^{n} (X_i - \bar{X})^2$$

Pourquoi $n - 1$?

- Correction du biais.

Cadre du problème

Si on Estime la variance avec $\frac{1}{n}$:

$$S_n^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i - \bar{X})^2.$$

Objectif : calculer $\mathbb{E}[S_n^2]$.

Décomposition utile

On utilise l'identité :

$$\sum_{i=1}^{n}(X_i - \bar{X})^2 = \sum_{i=1}^{n}(X_i - m)^2 - n(\bar{X} - m)^2.$$

Donc :

$$S_n^2 = \frac{1}{n}\left(\sum_{i=1}^{n}(X_i - m)^2 - n(\bar{X} - m)^2\right).$$

On prend l'espérance.

Preuve

On sait que :

$$\mathbb{E}\left[\sum_{i=1}^{n}(X_i - m)^2\right] = n\sigma^2,$$

et

$$\mathbb{E}\left[(\bar{X} - m)^2\right] = \mathrm{Var}(\bar{X}) = \frac{\sigma^2}{n}.$$

Donc :

$$\mathbb{E}[S_n^2] = \frac{1}{n}\left(n\sigma^2 - n\frac{\sigma^2}{n}\right).$$

Résultat final

On obtient :

$$\mathbb{E}[S_n^2] = \frac{1}{n}\left(n\sigma^2 - \sigma^2\right) = \frac{n-1}{n}\sigma^2.$$

$$\boxed{\mathbb{E}[S_n^2] = \frac{n-1}{n}\sigma^2}$$

Donc l'estimateur avec $\frac{1}{n}$ est biaisé :

$$\mathrm{Biais}(S_n^2) = -\frac{\sigma^2}{n}.$$

C'est pourquoi on utilise :

$$\frac{1}{n-1}$$

pour obtenir un estimateur sans biais.

4.2) Maximum de vraisemblance

Idée intuitive

On observe un échantillon :

$$X_1, X_2, \ldots, X_n$$

On suppose que les données suivent une loi dépendant d'un paramètre θ.

Question :

Quelle valeur de θ rend les données les plus probables ?

Fonction de vraisemblance

Supposons que $X_1, \ldots, X_n$ sont i.i.d.
Densité : $f(x|\theta)$
La vraisemblance est :

$$L(\theta) = \prod_{i=1}^{n} f(X_i|\theta)$$

On considère les données fixes et θ variable.

Log-vraisemblance

On prend souvent le logarithme :

$$\ell(\theta) = \log L(\theta) = \sum_{i=1}^{n} \log f(X_i|\theta)$$

Pourquoi ?

- Plus simple à dériver.
- Transforme un produit en somme.

Définition

L'estimateur du maximum de vraisemblance est :

$$\hat{\theta}_{MLE} = \arg\max_{\theta} L(\theta)$$

ou équivalemment :

$$\hat{\theta}_{MLE} = \arg\max_{\theta} \ell(\theta)$$

Densité normale

$$f(x|m,\sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-m)^2}{2\sigma^2}\right)$$

La vraisemblance :

$$L(m,\sigma^2) = \prod_{i=1}^{n} f(X_i|m,\sigma^2)$$

Log-vraisemblance (σ^2 connue)

$$\ell(m) = -\frac{n}{2}\log(2\pi\sigma^2) - \frac{1}{2\sigma^2}\sum_{i=1}^{n}(X_i - m)^2$$

On dérive par rapport à m :

$$\frac{d\ell}{dm} = \frac{1}{\sigma^2}\sum_{i=1}^{n}(X_i - m)$$

Condition d'optimalité

On annule la dérivée :

$$\sum_{i=1}^{n}(X_i - m) = 0$$

$$\sum X_i - nm = 0$$

Donc :

$$\hat{m}_{MLE} = \frac{1}{n}\sum_{i=1}^{n} X_i = \bar{X}$$

Estimateur de σ^2

On obtient :

$$\hat{\sigma}^2_{MLE} = \frac{1}{n}\sum_{i=1}^{n}(X_i - \bar{X})^2$$

Attention :

- Ici on divise par n
- Ce n'est pas l'estimateur non biaisé

Remarque importante

Le MLE peut être biaisé.
Pour la variance :

$$\frac{1}{n} \quad \text{(MLE)}$$

$$\frac{1}{n-1} \quad \text{(estimateur non biaisé)}$$

En pratique moderne :
Petit échantillon, cadre théorique $\rightarrow 1/n$
Grand échantillon, ML, optimisation $\rightarrow 1/n-1$

Résumé

- La vraisemblance mesure à quel point les données sont compatibles avec un paramètre.
- Le MLE maximise cette compatibilité.
- Pour la loi normale :

$$\hat{m} = \bar{X}$$

$$\hat{\sigma}^2 = \frac{1}{n}\sum(X_i - \bar{X})^2$$

4.3) Intervalles de confiance

- Intervalle de confiance
- Test d'hypothèse (idée générale)
- Lien avec la prise de décision

Pourquoi un intervalle ?

On a estimé :

$$\hat{m} = \bar{X}$$

Mais :

- $\bar{X}$ varie d'un échantillon à l'autre.
- Il existe une incertitude.

On veut encadrer la vraie valeur m.

Définition

Un **intervalle de confiance** (IC) pour un paramètre θ est un intervalle aléatoire :

$$IC = [L(X), U(X)]$$

tel que :

$$P(\theta \in IC) = 1 - \alpha$$

où :

- $1 - \alpha$ = niveau de confiance (95%, 99%, etc.)
- α = risque d'erreur

IC pour la moyenne (variance connue)

Soit $X_1, \ldots, X_n$ iid avec :

$$X_i \sim \mathcal{N}(m, \sigma^2)$$

On sait que :

$$\bar{X} \sim \mathcal{N}\left(m, \frac{\sigma^2}{n}\right)$$

Alors :

$$Z = \frac{\bar{X} - m}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$$

Construction de l'intervalle de confiance

Donc pour $z_{\alpha/2}$ tel que

$$P(-z_{\alpha/2} \leq Z \leq z_{\alpha/2}) = 1 - \alpha, \quad Z \sim \mathcal{N}(0,1),$$

on a

$$P\left(-z_{\alpha/2} \leq \frac{\bar{X} - m}{\sigma/\sqrt{n}} \leq z_{\alpha/2}\right) = 1 - \alpha.$$

Alors :

$$P\left(\bar{X} - z_{\alpha/2}\frac{\sigma}{\sqrt{n}} \leq m \leq \bar{X} + z_{\alpha/2}\frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha.$$

Donc l'intervalle de confiance est :

$$IC_{1-\alpha} = \left[\bar{X} - z_{\alpha/2}\frac{\sigma}{\sqrt{n}}, \bar{X} + z_{\alpha/2}\frac{\sigma}{\sqrt{n}}\right].$$

Interprétation correcte

Un IC à 95% signifie :

Interprétation correcte

Si on répète l'expérience un grand nombre de fois, 95% des intervalles construits contiendront le vrai paramètre.

La **marge d'erreur** est :

$$\boxed{E = z_{\alpha/2} \frac{\sigma}{\sqrt{n}}}$$

Donc :

$$IC = \bar{X} \pm E$$

Test d'hypothèse

Idée générale

Un test d'hypothèse permet de décider entre :

- H_0 : hypothèse nulle
- H_1 : hypothèse alternative

Exemple :

$$H_0 : m = m_0$$

$$H_1 : m \neq m_0$$

Règle de décision en fonction de $\bar{X}$

On teste :

$$H_0 : m = m_0 \qquad \text{contre} \qquad H_1 : m \neq m_0$$

- Si m_0 appartient à
$$\left[\bar{X} - z_{\alpha/2}\frac{\sigma}{\sqrt{n}}, \bar{X} + z_{\alpha/2}\frac{\sigma}{\sqrt{n}}\right]$$
on ne rejette pas H_0.
- Sinon, on rejette H_0.

Étapes d'un test

1. Formuler H_0 et H_1
2. Choisir le niveau α
3. Calculer la statistique de test
4. Déterminer la région critique
5. Prendre une décision

II L'optimisation

Problème d'optimisation

On considère le problème d'optimisation

$$\min_{\mathrm{x} \in C} f(\mathrm{x}),$$

où C est une partie de$\mathbb{R}^d$ s'appelle l'espace des contraintes ; f est une fonction objectif (coût, perte, vraisemblance) typiquement

$$f(\mathrm{x}) = \frac{1}{n} \sum_{i=1}^{n} \ell(\mathrm{x}; \mathrm{a}_i, b_i) + \lambda R(\mathrm{x}).$$

- ℓ : fonction de perte (quadratique, logistique, hinge...)
- R : régularisation (ℓ_2, ℓ_1, ...)
- Objectif : trouver un minimum (global ou local) pour généraliser.

Notations et rappels d'analyse

- $\nabla f(\mathrm{x})$: gradient (vecteur des dérivées partielles).
- $\nabla^2 f(\mathrm{x})$: matrice Hessienne (symétrique si $f \in C^2$).
- f est L-lisse (gradient Lipschitz) si

$$\|\nabla f(\mathrm{x}) - \nabla f(\mathrm{y})\| \leq L\|\mathrm{x} - \mathrm{y}\|, \quad \forall \mathrm{x}, \mathrm{y}.$$

- f est μ-fortement convexe si

$$f(\mathrm{y}) \geq f(\mathrm{x}) + \nabla f(\mathrm{x})^T(\mathrm{y} - \mathrm{x}) + \frac{\mu}{2}\|\mathrm{y} - \mathrm{x}\|^2, \quad \forall \mathrm{x}, \mathrm{y}.$$

Principe de Descente de gradient (GD)

La descente de gradient utilise l'approximation linéaire :

$$f(\mathrm{x}+\mathrm{d}) \approx f(\mathrm{x}) + \nabla f(\mathrm{x})^T \mathrm{d}.$$

Pour minimiser, on choisit d dans la direction de plus forte pente : $\mathrm{d} = -\eta \nabla f(\mathrm{x})$, avec $\eta > 0$ le pas.

Algorithm 1 Descente de gradient (GD)

Require: f, x_0, $\{\eta_k\}$, tolérance ε

```
k ← 0
while ‖∇f(x_k)‖ > ε do
    x_{k+1} ← x_k − η_k ∇f(x_k)
    k ← k + 1
end while
return x_k
```

Pas constant

- $\eta_k = \eta$ constant.
- Simple, mais nécessite une bonne estimation de la constante de Lipschitz.
- Si f est L-lisse, le choix $\eta = 1/L$ garantit la décroissance.
- En pratique, on utilise souvent une valeur faible (ex. 10^{-3}) et on ajuste.

Pas décroissant

Pour éviter l'oscillation et assurer la convergence, on utilise des séries divergentes :

$$\eta_k = \frac{\eta_0}{\sqrt{k+1}} \quad \text{ou} \quad \frac{\eta_0}{k+1}.$$

Théorème

Si f est convexe, L-lisse, et $\sum_{k=0}^{\infty} \eta_k = \infty$, $\sum_{k=0}^{\infty} \eta_k^2 < \infty$, alors $f(x_k) \to f(x^*)$.

Recherche linéaire

- On choisit η_k qui satisfait les conditions d'Armijo :

$$f(\mathrm{x}_k - \eta \nabla f(\mathrm{x}_k)) \leq f(\mathrm{x}_k) - c_1 \eta \|\nabla f(\mathrm{x}_k)\|^2, \quad c_1 \in (0,1).$$

- Algorithme de rétrocession (backtracking) : partir d'un η initial, diviser par β jusqu'à satisfaction.
- Garantit la convergence et évite le réglage manuel.

Cas convexe L-lisse

Théorème (Gradient descent avec pas $\eta = 1/L$)

Soit f convexe et L-lisse. Alors

$$f(x_k) - f(x^*) \leq \frac{L\|x_0 - x^*\|^2}{2k}.$$

Preuve (schéma) :

- Utiliser la descente suffisante : $f(x_{k+1}) \leq f(x_k) - \frac{1}{2L}\|\nabla f(x_k)\|^2$.
- Puis majorer la somme des gradients par la différence des distances.

Cas fortement convexe

Théorème

Si f est μ-fortement convexe et L-lisse, avec $\eta = 2/(\mu + L)$ (pas optimal), alors

$$\|x_k - x^*\|^2 \leq \left(\frac{\kappa - 1}{\kappa + 1}\right)^{2k} \|x_0 - x^*\|^2,$$

où $\kappa = L/\mu$ est le conditionnement. La convergence est linéaire (géométrique).

- Le taux de convergence dépend du conditionnement : κ grand $\Rightarrow$ convergence lente.

Gradient stochastique (SGD)

Lorsque $f(\mathrm{x}) = \frac{1}{n}\sum_{i=1}^{n} f_i(\mathrm{x})$, on estime le gradient par un sous-ensemble :

$$\mathrm{x}_{k+1} = \mathrm{x}_k - \eta_k \frac{1}{|\mathcal{B}_k|} \sum_{i \in \mathcal{B}_k} \nabla f_i(\mathrm{x}_k).$$

- $\mathcal{B}_k$est un sous-ensemble aléatoire de l'ensemble d'entraînement
- Coût par itération indépendant de n (grands jeux de données).
- Convergence en moyenne : $\mathbb{E}[f(\mathrm{x}_k)] - f(\mathrm{x}^*) \leq O(1/\sqrt{k})$ (sous conditions).
- Très populaire en deep learning.

Approximation quadratique

On approxime f au second ordre autour de x_k :

$$f(\mathrm{x}_k + \mathrm{d}) \approx f(\mathrm{x}_k) + \nabla f(\mathrm{x}_k)^T \mathrm{d} + \frac{1}{2} \mathrm{d}^T \nabla^2 f(\mathrm{x}_k) \mathrm{d}.$$

En annulant le gradient de cette quadratique par rapport à d, on obtient :

$$\nabla f(\mathrm{x}_k) + \nabla^2 f(\mathrm{x}_k) \mathrm{d} = 0 \quad \Rightarrow \quad \mathrm{d}_k = -\nabla^2 f(\mathrm{x}_k)^{-1} \nabla f(\mathrm{x}_k).$$

La direction de Newton d_k minimise la quadratique locale.

Algorithme de Newton

Algorithm 2 Newton (pure)

Require: f, x_0, tolérance ε

```
k ← 0
while ‖∇f(x_k)‖ > ε do
    Calculer H_k = ∇²f(x_k)
    Résoudre H_k d_k = −∇f(x_k)
    x_{k+1} ← x_k + d_k
    k ← k + 1
end while
return x_k
```

Convergence quadratique

Théorème

Soit $f \in C^2$, $\nabla^2 f$ Lipschitzienne au voisinage d'un minimum x^* avec $\nabla^2 f(x^*)$ définie positive. Alors il existe $\delta > 0$ tel que si $\|x_0 - x^*\| \leq \delta$, la méthode de Newton converge et

$$\|x_{k+1} - x^*\| \leq C\|x_k - x^*\|^2.$$

- Le nombre de chiffres significatifs double à chaque itération (convergence très rapide).
- Inconvénient : nécessite un point de départ suffisamment proche.

Problèmes de la méthode de Newton

1. **Coût de calcul** : $O(d^3)$ pour l'inversion de la Hessienne, $O(d^2)$ pour la construction.
2. **Hessienne non définie positive** : la direction n'est pas de descente.
3. **Sensibilité au point initial** : peut diverger si trop loin.
4. **Stockage** : matrice $d \times d$ impossible en grande dimension.

Remèdes

- **Newton modifié** : ajout d'un pas α_k par recherche linéaire :

$$x_{k+1} = x_k + \alpha_k d_k, \quad \alpha_k \text{ satisfaisant Armijo.}$$

- **Newton régularisé** : remplacer H_k par $H_k + \lambda I$ (Levenberg-Marquardt) pour garantir la positivité.
- **Quasi-Newton** : approximation de la Hessienne à partir des gradients successifs.

Régression linéaire : Nuage de points

On observe des données :

$$(x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n)$$

Représentation graphique :

- Chaque point représente une observation.
- On observe une tendance approximativement linéaire.

Question :

Peut-on approximer ces points par une fonction affine ?

Régression linéaire

Régression linéaire : ajustement d'un nuage de points

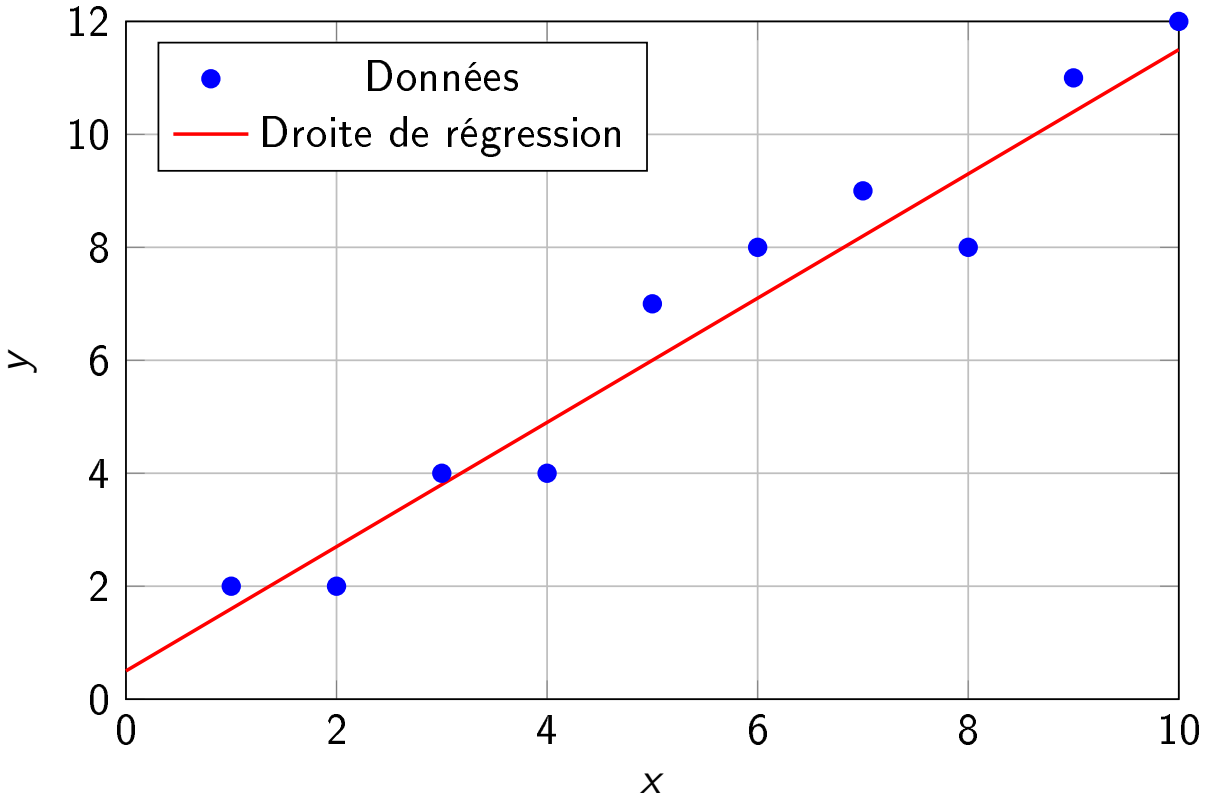

La droite minimise la somme des carrés des résidus (distances verticales).

Modèle : Fonction affine

On cherche une fonction :

$$y = ax + b$$

qui approxime le nuage de points pour prédire des valeurs continues y (ex : ventes, prix) en analysant des tendances.

Principe des moindres carrés

On définit l'erreur au point i :

$$e_i = y_i - (aX_i + b)$$

Par le Principe des moindres carrés, On veut minimiser l'erreur globale.

$$min_{a,b} F(a,b) = \sum_{i=1}^{n} (y_i - aX_i - b)^2$$

Pourquoi le carré ?

- Évite les compensations positives/négatives.
- Donne un problème d'optimisation convexe.

Résultat final

Les valeurs exactes de a et b sont :

$$a = \frac{\mathrm{Cov}(X, Y)}{\mathrm{Var}(X)}$$

$$b = \bar{Y} - a\bar{X}$$

Petit exemple

Points :

$$(1,2),(2,3),(3,5)$$

On calcule :

$$\bar{X} = 2 \quad \bar{y} = \frac{2+3+5}{3} = \frac{10}{3}$$

Puis on applique la formule pour obtenir a et b.

logique du Machine Learning moderne

La régression linéaire consiste à :

1. Choisir une forme de fonction (affine).
2. Définir une mesure d'erreur.
3. Minimiser cette erreur.
4. Faire des prédictions.

C'est exactement la logique du Machine Learning moderne.

Régression linéaire par descente de gradient

- Modèle : $\hat{y}_i = ax_i + b$
- Coût (erreur quadratique moyenne) :

$$J(a, b) = \frac{1}{2n} \sum_{i=1}^{n} (y_i - (ax_i + b))^2$$

- Gradients :

$$\frac{\partial J}{\partial a} = -\frac{1}{n} \sum_{i=1}^{n} x_i (y_i - (ax_i + b)) \qquad \frac{\partial J}{\partial b} = -\frac{1}{n} \sum_{i=1}^{n} (y_i - (ax_i + b))$$

- Mise à jour (pas η) :

$$a \leftarrow a - \eta \frac{\partial J}{\partial a}, \quad b \leftarrow b - \eta \frac{\partial J}{\partial b}$$

Application directe : la descente de gradient tend vers le même minimum sans passer par Cov, Var... La solution par descente de gradient est préférable pour les jeux de très grands volumes.

Régression logistique : modèle

- On observe :

$$(X_i, Y_i), \quad Y_i \in \{0, 1\}$$

- Objectif :Prédire le Succès : Y=1 Sachant X :

$$P(Y = 1|X)$$

- On Suppose :

$$p(y = 1|\mathrm{x}, \mathrm{w}) = \sigma(\mathrm{w}^T \mathrm{x} + \mathrm{b})$$

  où

- $$\sigma(z) = \frac{1}{1 + e^{-z}}$$

- w : vecteur des poids .
- bs'appelle le biais.

Régression logistique : données binaires et courbe de probabilité

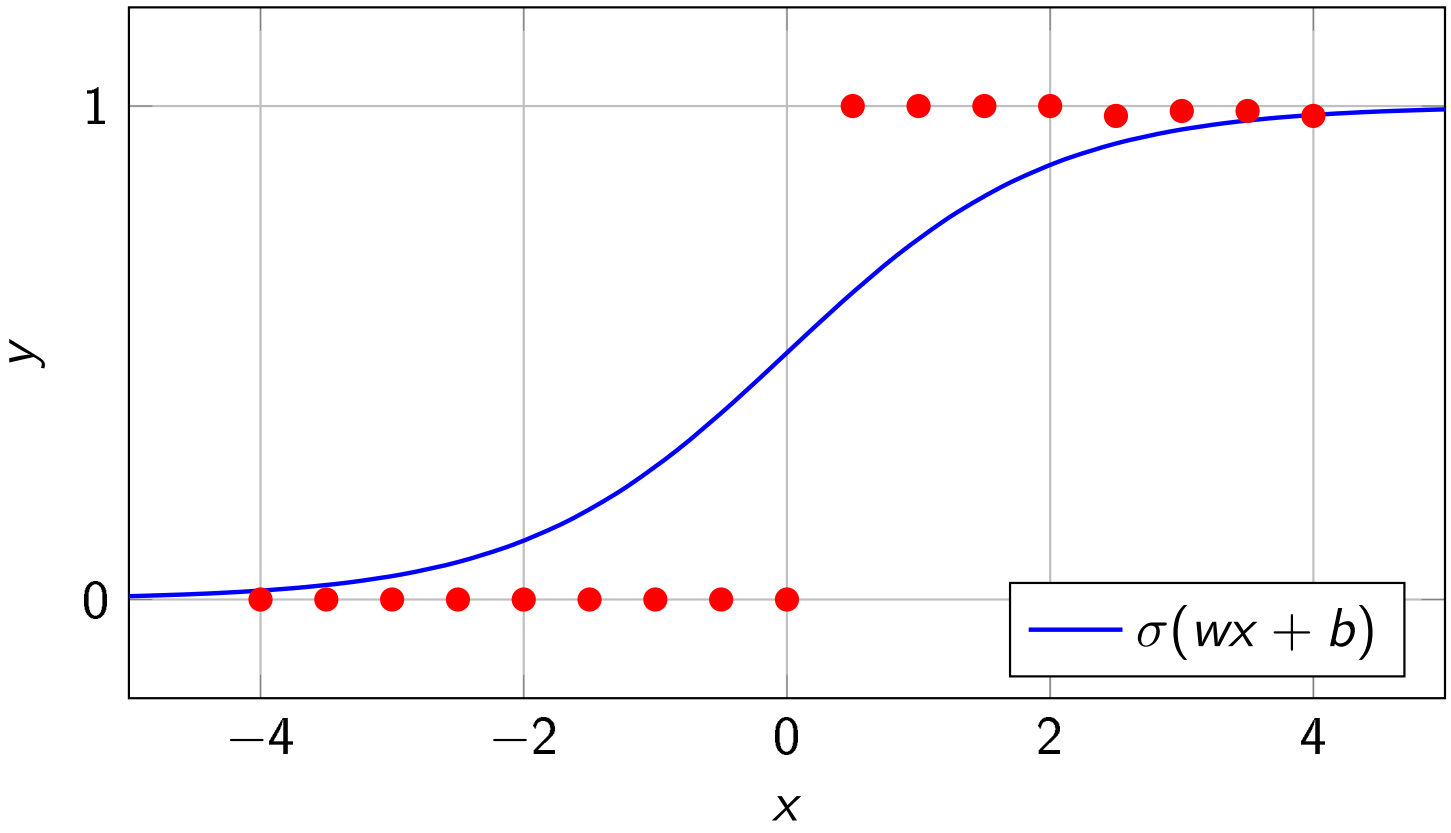

Pour chaque x, y suit une loi de Bernoulli de paramètre $\sigma(wx + b)$. Le biais b permet de décaler horizontalement la courbe.

Vraisemblance et log-vraisemblance

Pour n observations (x_i, y_i) indépendantes, la vraisemblance est :

$$L(\mathrm{w}, b) = \prod_{i=1}^{n} \sigma(\mathrm{w}^T \mathrm{x}_i + b)^{y_i} \big(1 - \sigma(\mathrm{w}^T \mathrm{x}_i + b)\big)^{1-y_i}$$

On maximise $\log L(\mathrm{w}, b)$:

$$\ell(\mathrm{w}, b) = \sum_{i=1}^{n} \big[y_i \log \sigma(\mathrm{w}^T \mathrm{x}_i + b) + (1 - y_i) \log\big(1 - \sigma(\mathrm{w}^T \mathrm{x}_i + b)\big)\big]$$

Problème de maximisation : $\max_{\mathrm{w}, b} \ell(\mathrm{w}, b)$.

Passage à une minimisation

Pour utiliser la descente de gradient, on minimise la *log-vraisemblance négative* :

$$J(\mathrm{w}, b) = -\ell(\mathrm{w}, b) = -\sum_{i=1}^{n} \big[y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i) \big], \quad \hat{y}_i = \sigma(\mathrm{w}^T \mathrm{x}_i + b)$$

C'est l'entropie croisée.

Gradient

Le gradient de J par rapport à w et b est :

$$\nabla_{\mathrm{w}} J = \sum_{i=1}^{n} (\hat{y}_i - y_i)\mathrm{x}_i, \qquad \frac{\partial J}{\partial b} = \sum_{i=1}^{n} (\hat{y}_i - y_i)$$

ou, sous forme moyenne :

$$\nabla_{\mathrm{w}} J = \frac{1}{n} \sum_{i=1}^{n} (\hat{y}_i - y_i)\mathrm{x}_i, \quad \frac{\partial J}{\partial b} = \frac{1}{n} \sum_{i=1}^{n} (\hat{y}_i - y_i)$$

La descente de gradient sur J :

$$\mathrm{w}_{k+1} = \mathrm{w}_k - \eta \nabla_{\mathrm{w}} J, \quad b_{k+1} = b_k - \eta \frac{\partial J}{\partial b}$$

Régression logistique : données binaires et courbe de probabilité

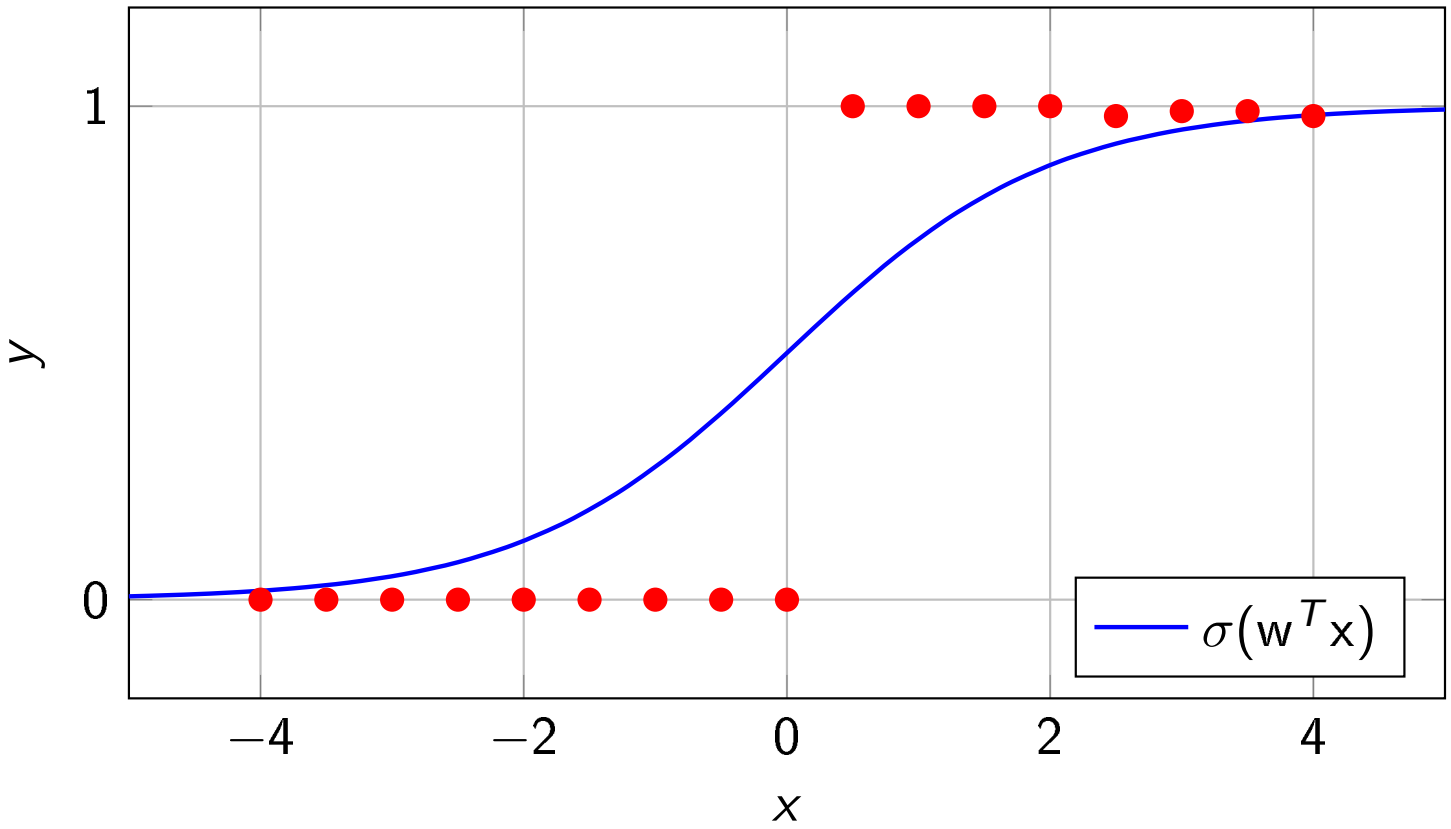

Pour chaque x, y suit une loi de Bernoulli de paramètre $\sigma(\mathrm{w}^T\mathrm{x})$.

Vraisemblance et log-vraisemblance

Pour n observations (x_i, y_i) indépendantes, la vraisemblance est :

$$L(\mathrm{w}) = \prod_{i=1}^{n} \sigma(\mathrm{w}^T \mathrm{x}_i)^{y_i} \big(1 - \sigma(\mathrm{w}^T \mathrm{x}_i)\big)^{1-y_i}$$

On maximise $\log L(\mathrm{w})$:

$$\ell(\mathrm{w}) = \sum_{i=1}^{n} \big[y_i \log \sigma(\mathrm{w}^T \mathrm{x}_i) + (1 - y_i) \log\big(1 - \sigma(\mathrm{w}^T \mathrm{x}_i)\big)\big]$$

Problème de maximisation : $\max_{\mathrm{w}} \ell(\mathrm{w})$.

Passage à une minimisation

Pour utiliser la descente de gradient, on minimise la *log-vraisemblance négative* :

$$J(\mathrm{w}) = -\ell(\mathrm{w}) = -\sum_{i=1}^{n} \big[y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i) \big], \quad \hat{y}_i = \sigma(\mathrm{w}^T \mathrm{x}_i)$$

C'est l'entropie croisée.

Gradient

Le gradient de $J(\mathrm{w})$ par rapport à w est :

$$\nabla J(\mathrm{w}) = \sum_{i=1}^{n} (\hat{y}_i - y_i)\mathrm{x}_i$$

ou, sous forme moyenne :

$$\nabla J(\mathrm{w}) = \frac{1}{n} \sum_{i=1}^{n} (\hat{y}_i - y_i)\mathrm{x}_i$$

La descente de gradient sur J :

$$\mathrm{w}_{k+1} = \mathrm{w}_k - \eta \nabla J(\mathrm{w}_k)$$

Références

- La fonction J est convexe (car l'entropie croisée avec sigmoïde est convexe).
- Descente de gradient (ou montée) converge vers l'unique minimum (maximum) pour un pas bien choisi.
- Pour de grands jeux de données, on utilise la descente de gradient stochastique (SGD) .

Références

- Boyd, S. et Vandenberghe, L. (2004). *Convex Optimization*. Cambridge University Press.
- Nocedal, J. et Wright, S. (2006). *Numerical Optimization*. Springer.
- Goodfellow, I., Bengio, Y., et Courville, A. (2016). *Deep Learning*. MIT Press.
- Polyak, B. (1987). *Introduction to Optimization*. Optimization Software.